

课程项目开题报告（Proposal）

支持长期记忆的对话 Agent

一、选题

1.1 课题名称

长期记忆对话 Agent（Long-Term Memory Agent）—— 一个支持跨会话记忆提取、检索与冲突更新的对话系统。

1.2 选题背景与动机

大语言模型本身是无状态的：每次对话结束后并不保留用户信息。如何让 Agent 在跨会话、跨时间的交互中记住、回忆并更新用户信息，是当前活跃的研究方向。

一个关键且常被忽视的问题是记忆冲突：在 `append-only`（只追加）式存储下，同一事实在不同会话中被修改后，向量库中会同时存在过时记忆与最新记忆。例如用户先说“我养了一只猫”，数次会话后说“我的猫去世了”——检索时两条矛盾记忆很可能被同时召回，导致生成被误导。本项目聚焦这一具体问题，实现冲突检测后的记忆更新机制，并以干净的消融实验验证其有效性。

1.3 对文献的定位

本项目在四篇必读文献中，主要参考并改进 Mem0（Chhikara et al., ECAI 2025）的工程化思路：其“记忆提取 → 冲突检测 → 更新”流水线是本项目探索方向的直接来源。检索环节借鉴 Generative Agents（Park et al., UIST 2023）中 `query` 与记忆单元的语义相关性匹配思想。评测数据与问题分类沿用 Evaluating Very Long-Term Conversational Memory（Maharana et al., ACL 2024）的 LoCoMo 基准。MemoryBank（Zhong et al., AAIL 2024）的遗忘曲线作为相关工作了解，不在本项目实现范围内。

二、组队情况

本项目由 2 人组队完成。

姓名	学号	分工角色	主要负责模块
王佳豪	231880404	队长	Memory Writer 、 Memory Updater （探索方向核心）
徐朱泽	231880414	队员	Memory Store 、 Memory Retriever、 Agent Controller

三、研究计划

3.1 核心目标

- 从跨会话的多轮对话中自动提取并结构化存储记忆单元；
- 回答新问题时检索相关记忆，辅助生成；
- 实现记忆冲突检测与更新机制（本项目选择的探索方向）；

- 在 LoCoMo 简化评测集上跑通全集并得到可量化、按问题类型拆解的结果。

3.2 系统架构

系统由五个核心模块组成：

- **Memory Store** —— 基于 FAISS 的向量索引，存储派生的记忆单元（非原始对话切片），每条记忆带时间戳、来源会话 ID 等元数据；
- **Memory Writer** —— 在每个会话结束后，用 LLM prompt 从该会话的多轮对话中批量提取结构化记忆单元；
- **Memory Retriever** —— 给定新问题，用 embedding 做稠密检索，召回 top-k 相关记忆；
- **Memory Updater** —— 探索方向的核心，实现冲突检测与更新 / 合并 / 去重；
- **Agent Controller** —— 主流程编排：会话写入 → 检索 → 拼接 prompt → 生成。

关键设计原则：严格区分“原始对话日志”与“派生记忆单元”，不把原始对话直接入库当记忆；所有记忆操作可追踪——每次问答记录检索到的记忆内容、完整 prompt 与模型输出，便于事后 bad case 分析。

3.3 探索方向：记忆更新（冲突检测）

本项目选择探索方向 C（记忆更新 / 冲突检测）作为唯一探索方向，集中做深，不做第二方向。选择理由有三：

- 该方向直接对应 LoCoMo 评测集的“信息更新追踪”问题子类，消融效果能清晰落到该类题型的准确率上；
- 对照设计天然干净——固定数据、固定生成模型，仅替换 Memory Updater 模块；
- 该机制是 Mem0 的核心，实现后具有明确的技术深度，便于在报告中展开。

消融对照设置两组配置：

- 配置 A（基线）：**append-only**。新提取的记忆一律追加入库，不做任何冲突判断。
- 配置 B（探索）：**冲突检测 + 更新**。新记忆写入前，先检索语义相近的已有记忆，由 LLM 判断二者关系（无关 / 重复 / 矛盾更新），据此决定追加、去重，或用新记忆覆盖 / 合并旧记忆。

两组配置使用相同数据、相同生成模型，仅 Memory Updater 模块不同，确保消融干净。

3.4 实验设计

基线对照（四组，均必做，共用同一生成模型）：**No-memory**（仅当前 query）、**Full-context**（塞入全部对话历史并截断）、**Vanilla RAG**（对原始对话切片做向量检索）、本系统。

探索消融：配置 A（append-only）vs. 配置 B（冲突检测更新），同数据同模型。

结果汇报：按 LoCoMo 四类问题（单会话回忆、跨会话回忆、时间推理、信息更新追踪）分别报告准确率，不只给总数；从失败样例中选 3–5 条做 bad case 分析，定位问题出在写入丢失 / 检索未命中 / 生成未利用哪一环。

评测指标：QA 准确率（助教脚本，LLM-as-Judge，主指标）、平均每题 LLM 调用次数（成本指标）、平均端到端响应时间。目标：总体准确率不低于 Vanilla RAG，争取达到 Vanilla RAG + 5pp。

3.5 模型与资源约定

本项目全程调用云端 API，不做本地模型部署。

- 生成阶段：统一使用同一开源 API 模型（如 SiliconFlow / DashScope 上的 Qwen2.5-7B-Instruct）。四个 baseline 与本系统共用此模型，以满足作业“所有对照实验必须使用同一底座模型”的要求；
- Judge 阶段：使用 DeepSeek 等价格低廉的云端模型，与生成模型异源，以规避 self-evaluation bias；
- Embedding：使用 BAAI/bge-small-zh-v1.5，本地 CPU 即可运行，无需 GPU；
- API Key 安全：置于 .env 文件并加入 .gitignore，两名成员各自使用独立 Key，避免费用纠纷。

3.6 时间计划

结合课程三个节点（5/17 Proposal、6/3 Milestone、6/17 Final 答辩），以“先小样本打通、再上全集”为原则排期，并为英文论文写作预留独立时间块：

时间	工作内容
第 1 周（5/17–5/23）	申请并配置云端 API；搭建四个 baseline 骨架；用 5–10 条样本打通“对话输入 → 写入 → 检索 → 生成 → 评测”全链路。
第 2 周（5/24–5/30）	实现 Memory Writer 与配置 A（append-only），完成本系统基线版本；跑通全集评测。
6/3 Milestone 节点	提交进展报告：已有四个 baseline + 配置 A 的初步结果；下一步计划为实现冲突检测消融。
第 3 周（5/31–6/6）	实现 Memory Updater 配置 B（冲突检测与更新）；完成 A/B 消融实验；按题型拆解结果。
第 4 周（6/7–6/13）	bad case 分析；补充成本与延迟指标；同步开始撰写英文论文（ACL 模板，8–9 页）。
冲刺（6/14–6/17）	英文论文定稿；准备答辩 PPT；整理代码与提交目录；6/17 答辩。

说明：英文论文不留待最后三天，第 4 周即与实验并行动笔，以保证 ACL 模板 8–9 页正文的写作质量。

3.7 预期成果与风险

预期成果：一个可端到端运行的长期记忆对话 Agent；四组 baseline 与一组干净消融的完整实验结果（按题型拆解）；3–5 条 bad case 分析；ACL 模板英文论文与答辩材料。

主要风险与应对：（1）API 调用成本与限流——先用小样本调通流水线，控制全集评测的调用次数；（2）记忆提取质量不稳定——Prompt 工程保留在配置文件而非硬编码字符串中，便于迭代替换；（3）时间紧张——严格控制在一个探索方向，不扩展第二方向，确保稳过。

3.8 主要参考文献

- Park et al. Generative Agents: Interactive Simulacra of Human Behavior. UIST 2023.
- Zhong et al. MemoryBank: Enhancing Large Language Models with Long-Term Memory. AAAI 2024.

- Chhikara et al. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. ECAI 2025.
- Maharana et al. Evaluating Very Long-Term Conversational Memory of LLM Agents. ACL 2024.